

数据组作业说明：科学训练数据 Pipeline 设计

GR/SR 动力学与运动学方向



发布日期：2026 年 5 月 16 日

1. 作业概览

截止时间：发布后 2 周（2026 年 5 月 30 日）。

Checkpoint：发布后 1 周（2026 年 5 月 23 日），需提交一次中期材料。

每人独立提交一份**科学训练数据制备 pipeline**。提交形式不限，可以是：

- 一组 Claude Code 的 *skills*;
- 独立的代码仓库 (Python/Bash/Jupyter 均可);
- 一段与 Claude Code 的对话记录 (完整可重放)。

无论哪种形式，必须保证可复现性：他人按你给出的指令、依赖与种子 (seed)，应当能够得到等价的（统计意义上分布相同的）输出。

2. 背景与最终目标

我们想要回答的问题是：能否通过一组各自结构清晰、行为受控的 pipeline，将少量**种子题目** (seed problems) 扩展成一个**规模化的、内部多样的科学训练集**？这一数据集最终的用途包括：

- 训练**小尺度的 LLM**（例如以 Qwen-8B 量级模型为目标），使其在科学任务上获得显著提升；
- 用于**设计 agent**：当 agent 调度工具完成科学推理时，它的”科学常识”与”运算耐心”来自此类数据。

每个人单独写的 pipeline 之所以重要，是因为我们之后会做的事情是：**对所有人的 pipeline 取共性、定问题类型、相互融合与交叉**，形成覆盖更广、内部相关性可控的科学数据集。因此你不需要担心”自己的 pipeline 太单一”——你应当担心的是它**是否清晰、是否可被其他 pipeline 嫁接**。

3. 科学范围与难度

3.1 学科范围

本次只关心**广义相对论 (GR)** 与**狭义相对论 (SR)** 中的题目，覆盖：

- 任意阶的**微扰动力学/运动学**（如弱场展开、后牛顿展开、引力波线性化等）；

- 非微扰动力学/运动学（精确解、对称性约化、数值积分、近视界几何等）；
- 与之直接相关的内容（张量分析、测地线、参考系变换、守恒量、能动量、因果结构等）。

3.2 难度定位

最终我们希望训练出的模型在这部分数据上的 SOTA 对标 **Qwen-8B 量级**。因此你设计的题目难度需要满足下述至少一条：

1. 求解过程中至少需要一次 **GR 相关工具调用**（如符号张量计算、度规分量化简、测地线方程数值求解等）；或
2. 难度**超过 CPhO 决赛水准**（即仅靠中学物理直觉与解析技巧不足以稳定解出）。

不要求你给”难度”打一个统一的数值分数——每个人对难度的定义不同，强行打分反而不利于后续合并。

但建议你为每条输出附上一些**描述性的元信息**，比如：是否调用了工具、调用了哪个、推导大致几步、依赖了什么前置概念。这些信息将来用来筛选与组合，比一个 1/2/3 的分数有用得多。

4. 对 Pipeline 的要求

我们把这次的 pipeline 视为一个**训练数据制备 pipeline**，它应当具备如下三个核心性质：

1. **概率性输出**。pipeline 的某些环节必须依赖 LLM 或工具的有随机性的输出，而不是确定性脚本。典型来源：LLM 采样、工具的多个等价输出（如不同坐标系下的同一答案）、题目模板的随机填充等。
2. **语义-数据之间的转换多样性**。同一份”种子信息”应当能被映射为不同表层形式的数据。例如：同一道引力红移题目可以被改写为问答、推导、代码题、概念辨析等多种形态。
3. **漏斗结构**。从少量种子出发，最终产出**显著更多、内容更丰富**的训练样本。我们至少要看到”一进多出”，且后续样本之间不是简单复制。

最小可接受目标：**1 个种子**经过你的 pipeline 后，产出 ≥ 5 条彼此不平凡不同的训练样本（既不是同一题改个数字、也不是同一段话换个措辞）。

4.1 推荐的设计起点（仅作参考）

1. 先**粗略浏览**你感兴趣的小方向（SR、流形与张量、Schwarzschild/Kerr、线性化引力波等任选其一即可），不必一开始就把整套理论吃透；
2. 选定一个**你能讲清楚一道具体题目**的小范围，写下种子题目和你自己的完整解；
3. 设计 pipeline：在哪一步引入 LLM？在哪一步调用工具（如 xAct、EinsteinPy、SymPy 张量模块、有限差分等）？在哪一步做语义改写、难度调整、错误注入与去重？
4. 在设计 pipeline 的过程中**按需补理论**：当你发现自己讲不清一个推导、或不知道怎么写校验时，再回去把那块学透。

理论学习建议在设计过程中按需推进，而不是先全盘掌握再开始设计。

GR 是个大坑，等你”准备好”再动手，2 周时间一定不够。正确的姿势是：用你想做的题目反过来定义你要学什么。但有一条底线：你最终交上来的题目，每一步推导你自己必须能讲明白。

5. 提交物清单

最终（第 2 周末）需要提交以下三部分：

1. **报告**（PDF 或 Markdown 均可）：
 - 完整、忠实地记录所有相关技术细节；
 - 明确区分作者**确定**的内容与**不确定/未验证**的内容（后者尤其重要，便于后续审阅与合并）；
 - 记录失败的尝试也算分。
2. **Pipeline 设计方案 + 代码 / skills / 对话记录**：保证按 README 步骤可以复现一次完整运行。
3. **最终输出的数据**：至少满足第 3 条的漏斗结构；每条数据需附带必要的元信息（来自哪个种子、所用工具、是否经过验证等）。

每条数据必须满足以下二选一：

- 给出**答案**（可以是数值、表达式、推导过程、判断结论等任意能称为”参考解”的内容）；或
- **显式标注”无答案”**（例如开放性问题、设计性问题、目前没把握做对的题目）。

两者都可接受，但不允许出现”没标答案、也没说没有”的题目——这种数据后续没法用，会直接被丢掉。

澄清责任边界：用 LLM + agent 把这些题目实际解出来、做 RL 训练或 agent 调度，是**后续 RL 组 / agent 组**的事情，不是数据组的任务。你不需要担心”我出的题目模型能不能做对”——那是下游问题。你的责任是：**题目本身正确、答案（或”无答案”标记）正确、pipeline 可复现**。

6. Checkpoint（第 1 周末）

发布后第 7 天结束前，将以下材料邮件发送到：

zhuoyangsong@stu.pku.edu.cn

Checkpoint 包含：

- 当前版本的报告（即使尚未完成）；
- 当前版本的 pipeline 代码 / skills / 对话；
- 当前已产出的数据样本（哪怕只有几条）。

附件大小请尽量控制小一些，邮箱接收能力有限。

建议：代码与报告直接发邮件；数据如果较大，请压缩并只发一个有代表性的子集（例如几十条样本足矣），完整数据可以放到网盘并附上链接。

如果到 **checkpoint** 你还没完成：请在邮件中明确说明当前进度和遇到的困难，以及你希望延期到何时。延期最长不得超过第 2 周末（即作业最终截止时间），不接受更长的延期。

7. 评估关注的点（非打分制）

这门作业的目的是学习，不是排名。我会重点看：

- 你对 GR/SR 题目本身的理解（题目设计得是否合理、解是否正确）；
- pipeline 的可复现性与可解释性（别人能不能在不问你的情况下跑通它）；
- 漏斗结构与多样性是否真的存在；
- 报告中“不确定的内容”是否被诚实地标出来。

8. 温馨提示

这次的题目对大一同学是有一定挑战的，所以：

- **不要等”学完理论”再开始。**挑一个你最感兴趣的小方向（比如 SR + 弱场近似、或者 Schwarzschild 测地线），在设计题目和 pipeline 的过程中按需把理论补上来，这样学得更快、也更知道自己学的东西要拿去干什么。
- 遇到不会的地方**大胆问**，问 Claude、问搜索引擎都可以；要找人问的话，**直接联系群里那个蓝色猫头像的人**，也可以联系王波。但最终交上来的题目，你自己必须能讲明白每一步——这是检验”按需学习”是否到位的唯一标准。
- Claude Code / 任何 LLM 都是工具。它会犯错，尤其在 GR 计算上；你的 pipeline 需要有最起码的校验环节（比如对照已知极限、单位检查、守恒量检查、和已知精确解对拍）。

祝顺利。日常问题在群里找宋卓洋或者王波；*checkpoint* 与最终提交请发到 zhuoyangsong@stu.pku.edu.cn。