

数据组作业说明（第二轮）：科学语料 → 批量训练题

Pipeline

GR/SR 方向 · 原型机交付



发布日期：2026 年 5 月 30 日

1. 任务概述

DDL：发布后 10 天（2026 年 6 月 9 日）。无 checkpoint。

自愿报名：<https://v.wjx.cn/vm/tTro5c8.aspx>

合作 / 独立都接受，以”组”为单位提交一份原型机（一个人也算一组）。

第一轮交付的是”种子题 → 一批样本”。本轮把入口往前推一步：**进口换成科学语料**（论文 / 教材章节 / 习题集），出口仍然是一批可用的训练题。每组要交付一个端到端可跑的原型机：给一份它没见过的语料，能产出一批带答案、带血缘、带验证记录的训练数据。

为什么要这么做：第一轮证明了”种子 → 样本”在每个人手上都能跑，但要规模化，”种子哪儿来”是下一个瓶颈。本轮把种子的源头也自动化掉。

附录 B 给出了一版参考原型机的实测数据。本轮提供完整代码骨架（路径见 §3），不想从零设计架构的组可以直接基于它扩展；想自己设计的组也可以另起。

1.1 两种工作模式（自由选其一或混合）

语料来源不限于论文。下面两种输入源都接受，对应的指标会有微调。

模式 A：论文输入

- 输入：arXiv tex / PDF / 预印本 URL；
- 难点：种子要靠 LLM 从长文本里抽取并生成；
- 指标： ≥ 50 篇论文，全组 ≥ 1000 道，放大比 $> 20\times$ （论文 → 入库题）。

模式 B：教材 / 习题集输入

- 输入：GR/SR 教材章节及其原配习题（如 Carroll、Schutz、MTW、Wald、Padmanabhan、Weinberg、Zee 等），或公开习题集；
- 难点：从纸质 / PDF 把题目和参考解结构化扒下来；扒下来之后这些题就是种子，Stage 0 简化为”OCR + 解析 + 清洗”，scale 阶段不变；
- 指标： ≥ 5 个章节（覆盖 ≥ 100 道原题作为种子），全组 ≥ 1000 道，放大比 $\geq 10\times$ （原题 → 衍生）。放大比要求降低是因为原题本身已经是高质量起点，主要工作量在 scale 与变体。

模式 C：混合

- 论文与教材合用，按比例满足。例如 25 篇论文 + 3 个章节 + 50 道扒题，全组 ≥ 1000 道。
- papers.json 里每个条目标 source_type {paper, textbook, problem_set}。

选哪种模式？教材模式上手更快、原题质量更高、答案更可靠，适合时间紧或对 OCR / PDF 解析有把握的组；论文模式自动化程度更高、扩展性更好，适合愿意调教种子提取的组。两者得到的训练数据风格不同，合并到同一数据集后多样性会更好。

2. 交付指标（分层目标）

下表把指标分成三档。要求是”基础线必达，核心质量是评估重点，加分项做到就更好”。

档位	内容	含义
基础线	pipeline 端到端可跑 / schema 合规 / 自检脚本齐全；模式 A: ≥ 30 篇, ≥ 600 道；模式 B: ≥ 3 章节, ≥ 60 原题种子, ≥ 600 道；模式 C: 等价折算	算交付完成。够这条就属”已完成”。
核心质量	基础线 + Stage 契约清晰 + 至少两层独立验证 + 多样性三轴各 ≥ 5 取值 + 失败模式分析具体	评估的主要参考。这一档够好的话指标差一点也无妨。
加分项	模式 A 满 50 篇 / 1000 道 / 模式 B 满 5 章节 / 自创 stage / 跨组合作 / ablation 实验	做到一些更好，做不到不影响核心评价。

第一周末建议自评一次进度大概在哪一档；如果基础线都没到，后几天的精力建议转去补基础线而不是优化 stage。

2.1 交付物清单（提交时必须有的东西）

下面四样是**每组都要给的**，缺了会被退回补交：

1. **统一 jsonl schema 的数据集 dataset.jsonl** (schema 见附录 A)。每条记录有 id / statement / answer (或 NO_ANSWER) / meta.lineage / verification。
2. **validate.py**: 跑一行 `python validate.py dataset.jsonl` 输出总条数、按论文/stage/题型/物理环境的分布表、schema 校验通过率、随机 10 条样例。
3. **sample.py**: `python sample.py dataset.jsonl --n 30 --by paper` 按维度抽样输出 mark-down 报告。
4. **run_report.md**: 端到端漏斗表 + 失败语料列表 + 跳过原因 + 平均 token 估算。

附录 C 给了 validate.py / sample.py / run_report.md 的可直接套用的骨架。

2.2 多样性的三个轴（鼓励但不卡死）

只做”题型变体”会让大量语料产出的题目同质化。本轮在第一轮的题型基础上再加两轴：

- **cognitive 题型**: derivation / numerical / conceptual / code / multiple_choice / open / 自创类别；

- **物理环境**（本轮新增）：把同类问题搬到不同背景：

- GR 时空：Schwarzschild / RN / Kerr / de Sitter / FLRW；
- SR 参考系：静止 / 匀速 / 加速；
- 微扰阶数：线性 / 二阶 / 后牛顿；
- 参数族：质量、电荷、自旋、 Λ sweep；

- **题型软改写**（本轮新增）：题型自然延伸：

- 对照题：相同问题在两种背景下结果对比；
- 校验题：给一段（可能错的）推导让模型找漏洞；
- 设计题：要求设计一个观测 / 数值实验来验证某结论；
- 归约题：从复杂结果取极限回到经典对应。

覆盖度推荐：每个轴至少 5 个不同取值。不强制，但满足这条会让数据集对下游训练更耐用。

2.3 质量软约束

允许的：参考解末位推导有小瑕疵 / 单位偶尔不严格 / 解释👎嗦但不错——只要在 `verification.judge.issue` 里如实写一句即可。

需要避免的：题目本身不可解（条件矛盾、依赖语料里没给的信息）且未被任何验证环节标出。这种数据会污染训练集。

下游目标是”**能够提升 Qwen-8B 在 GR/SR 上的表现**”，不是产生人工教材级别的范题。验证网仍要有两层独立（结构 + LLM 判官至少其一是判官，另一项可以是 sympy / 单位 / 极限 / 守恒量等任意客观校验）。允许某些题只过一层验证就入库，但要在 `verification` 里如实记录”哪一层跑了、哪一层没跑”，不要默认填 `ok=true`。

3. 原型机：参考实现

参考实现的代码与样例数据由助教统一打包提供，向宋卓洋索取最新版即可。

3.1 架构（直接借鉴）

```
一份语料（论文 .zip/.tex 或 教材章节 PDF/HTML）
|
v  Stage 0:  SeedStage
|    模式 A: LLM 读语料 -> 生成多样种子题 -> red-team 改进
|    模式 B: 解析/OCR -> 清洗 -> 已有题目即种子
|    出口评估（结构 + LLM judge），不合理则重跑
v
种子题 x N
|
v  Scale 流水线 = 把多个 stage 拼起来，对每个种子扇出
|    - CognitiveFanoutStage  (cbz/gjx/wsx 血缘)
|    - MetricSubstituteStage (dyc 血缘 + sympy 校验)
```

```

|      - SoftRewriteStage      (本轮新增：对照/校验/设计/归约)
|      每个 stage: 一个种子进 -> 一批题出 -> 评估 -> 不合理重跑
v
去重 + 训练价值打分 + 落盘
|
v
dataset.jsonl + run_report.md

```

3.2 承重思想：统一的 Stage 契约

所有 pipeline 都实现同一个抽象（30 行不到），这是”拼接”能成立的原因：

```

class Stage:
    def produce(self, item, attempt) -> list[Problem]:
        """ 进口进一个，出口出一批；由子类实现 """
        raise NotImplementedError

    def run(self, item): # 基类提供的统一外壳
        # produce() -> evaluate(outlet)
        # -> 合理？是：返回
        # 否：重跑 produce()（有限次，升温度）
        ...

```

设计要点：

- **进口/出口接口统一**（一个 Problem 进 / 一个 list[Problem] 出），这是 stage 能任意拼接的前提。Stage 0 的进口是语料是个例外，但 Stage 0 之后全是同构。
- **每个 stage 自带评估 + 重跑闭环**：上游不需要操心下游能不能用上游的输出，因为每个 stage 自己保证出口合格。
- **失败容忍**：重跑用完了仍不达标，输出”目前能拿出来的最好的一批”加 degraded 标记。整条链不会因为一个 stage 失败就崩。

时间紧的组建议直接套用这个 Stage 抽象 + fan_through 组合函数，然后只写各 stage 的 produce()。

3.3 三层验证（修复了上一轮的通病）

上一轮代码常见问题是”校验器写了但没接上”或”LLM 自己评 LLM”。原型机里把验证拆成三张独立的网，每张挂在 Stage.evaluators 列表里：

网	模块	性质 / 覆盖
结构网	evaluators/structural.py	无 LLM 的确定性闸门：批量大小、答案存在性、n-gram 去重。
独立符号网	core/sympy_verify.py	独立于生成模型的纯 sympy：度规真空判定、曲率、答案表达式恒等。
模型网	evaluators/judge.py	独立 LLM 调用：judge 找对错 + red-team 找漏洞，用不同 prompt + 不同温度。

两条建议：

1. **不要让生成模型自评。**Judge / red-team 必须是独立的 LLM 调用，prompt 写成“adversarial”（要求它找错而非确认对）。
2. **客观验证要选与题目结论相关的不变量。**给 Schwarzschild 题跑个 vacuum 判定不算“客观验证”，因为题目可能不依赖这个性质。要选题目答案直接用到的不变量。

3.4 原型机已经踩过的 7 个坑（直接避开）

按命中可能性排序：

1. **慢端点导致“假死”。**某些 LLM 端点（dashscope 上的 dsv4-pro、本地代理时的 anthropic）长 JSON 输出会卡到 SDK long-request 上限。**对策：**streaming + 显式 timeout 1800s + 失败转 None 不阻塞批；本机若有 clash/v2ray 代理，LLM 客户端进程要 `os.environ.pop` 掉 `HTTPS_PROXY/HTTP_PROXY/ALL_PROXY` 走直连。
2. **quota / 限流。**一篇论文跑完大约 10^5 量级输出 token（含判官与红队）。50 篇 $\sim 5 \times 10^6$ tokens。**对策：**多账户 / 多 endpoint 错峰，做完一批 cache 一批，磁盘缓存 key 用 (model, system, prompt, temperature) 的 sha256。
3. **一次让模型输出 6 个题型的 JSON 数组容易被截断。**max_tokens 不够、中间任一形式出错就拖累整批。**对策：**每个题型一次独立调用并发跑（线程池），per-item 失败转 None。原型机里这一改把 wall-clock 从 50min 压到 15min。
4. **多层验证之间的耦合错误。**LLM judge 会“放过”错的题、sympy 会“通过”本身没用上的几何性质。**对策：**red-team 要独立 prompt + 不同温度 + 不同模型（如可能）；客观验证要选题目答案直接相关的不变量。
5. **种子从语料里抽不出来（模式 A）。**综述论文段落多但具体推导少；非综述论文推导多但 self-contained 程度差。**对策：**先选 5-10 篇候选小规模试跑，看哪类出种子率高，再定主力名单。
6. **tex / PDF 大文件输入截断。**一篇 400K 字符直接进 prompt 会爆。**对策：**tex 截到 `\begin{document}` 与 `\end{document}` 之间，再按段加权采样到 20-30K 字符（数学密度高的段优先）。教材 PDF 走 OCR + chapter splitter。
7. **lineage 链断裂。**多人合并代码时容易在最后 dump 阶段丢掉 `meta.lineage`。**对策：**在 `validate.py` 里硬卡，缺 lineage 的记录直接 reject。

最容易被忽视的一条：判官调用本身可能是端到端瓶颈，因为它的输入是一批题的合集，输出又要逐题 verdict。不要假设“判官比生成快”。

3.5 原型机一次实测的真实数据

- 输入：1 篇论文（arXiv-1002.4928v2, $f(R)$ 引力综述, 423K chars）
- Stage 0 种子：2 道, judge mean TV=0.93
- Cognitive fanout ($\times 2$ seeds): 12 个变体生成 $\rightarrow$ 红队后 8 道入库
- Metric substitute ($\times 2$ seeds): 10 个变体生成 $\rightarrow$ 红队后 7 道入库
- 全局 dedup 后: **15 道入库** (amplification $1 \rightarrow 15$)
- 验证信号: red_team 13/15 通过、sympy 独立验证 4 道、TV mean=0.78、max=0.95

- 端到端耗时：158 分钟

15× 推到本轮模式 A 的 20× 怎么做：把 `n_extend` 从 2 提到 4、`substitute_metrics` 从 3 提到 5、`cognitive forms` 从 6 提到 8（加入”对照/校验/设计/归约”四类），单篇就能稳定上 25 道。

3.6 建议的开发顺序（10 天版）

1. **Day 1–2：**把原型机仓库下下来，跑通它的默认配置（一篇论文 → ~15 道），确认环境、API、磁盘缓存都对。
2. **Day 3–4：**对自选的 5 篇候选语料（或 1–2 个章节）跑通，统计哪类语料出种子率高，定下主力名单。这一步会暴露大部分隐性 bug。
3. **Day 5–7：**加宽 stage 配置（`forms / metrics / extend`），加上”物理环境”和”题型软改写”两个新轴，跑 10–20 份语料看产出形状。
4. **Day 8–9：**跑剩下的语料，全量产出 1000 道。
5. **Day 10：**写报告，跑 `validate.py / sample.py`，准备提交材料。

时间紧的从后往前砍：保 day 1–4 + day 8–10。core stage 沿用原型机，跑 30 篇语料拿 ~600 道仍然在基础线之上。

4. 评估关注的点

非打分制，下面几条是评估时会专门留意的：

- **诚实地标”做不到的事”：**partial 提交 + 一段具体的失败模式分析 > 全量提交 + ”什么都对”。
- **Pipeline 的可复现性：**一行命令、disk cache、新语料能跑出题。
- **验证网是否真有两层独立：**评估时会随机抽 30 条手工核对声称”对”的题，看里面有几条其实是错的。错率高不是大问题，关键是 `verification` 里是否标出了已知疑点。
- **多样性轴的真实覆盖：**50 篇语料里有没有真的横跨不同物理背景，或者全是同一类（都是 Schwarzschild、都是 SR）。

5. 提交方式

1. **先报名：**扫问卷 <https://v.wjx.cn/vm/tTro5c8.aspx> 填基本信息 + 是否组队 + 选定的工作模式（A / B / C）。建议第一周内报名，方便组间协调（避免重复造同款 stage）。
2. **最终提交：**DDL 当日（2026 年 6 月 9 日）邮件至 zhuoyangsong@stu.pku.edu.cn：
 - Pipeline 仓库（git 链接 / zip 均可）；
 - 数据集 jsonl（如较大走网盘 + 链接）；
 - `validate.py / sample.py / run_report.md`；
 - 报告（PDF 或 Markdown）；
 - `papers.json`（语料清单 + status）。

延期申请：邮件写明当前进度 / 卡点 / 希望延到几号，最长 +2 天。

6. 温馨提示

- **第一天先把原型机跑通。**哪怕只跑默认配置一份语料，跑完会对 wall-clock、token 消耗、出题质量有一个直观感觉，所有后续决策基于这个感觉。
- LLM 在 GR 计算上**依然会犯错**（原型机这次跑里 cognitive 阶段就有 sign error 被红队抓出来）。校验环节不能省，但也不必追求”零错”。
- **综述论文出种子率高但题目深度参差，单篇推导论文出种子难但深度高。**两类各放进主力名单一部分，覆盖更广。
- **模式 B 的 OCR / PDF 解析可能比想象中麻烦：**公式提取、图片处理、题号匹配、答案对应都有踩坑空间。建议先用一章 well-typed 的源（如 arXiv 上的教材源 tex）打通流程，再上 scanned PDF。
- **合作组里若有人卡了：**写清楚 ta 卡在哪、其余人继续推进，比”等齐了再交”被认可得多。
- **有问题随时问：**群里找宋卓洋或王波，Claude / 搜索引擎都可以问，论文级别的 GR 问题找王波最快。

祝顺利。报名 <https://v.wjx.cn/vm/tTro5c8.aspx>；日常问题群里找宋卓洋或王波；最终提交 zhuoyangsong@stu.pku.edu.cn。

A. 数据 Schema

每行一个 JSON 对象。**必须字段**（缺了会被 validate.py 拒收）和一条真实样本（来自原型机产出）：

```
{
  "id": "<short hash, globally unique>",
  "statement": "Consider f(R) gravity with action S = ... Compute ...",
  "answer": "<reference answer> | NO_ANSWER",
  "solution": "<full derivation> | empty if NO_ANSWER",
  "meta": {
    "source_id": "arXiv-1002.4928v2", // 论文/章节 ID
    "source_type": "paper", // paper / textbook /
      problem_set
    "stage": "scale:metric_substitute",
    "lineage": ["arXiv-1002.4928v2", "<seed_id>"],
    "topic": "f(R) gravity stability conditions",
    "concepts": ["f(R) gravity", "FLRW metric", "modified Friedmann"],
    "tools_used": ["llm_reasoning", "sympy_verify"],
    "cognitive_form": "derivation", // 题型轴
    "physics_env": "FLRW_flat", // 物理环境轴（本轮新增）
    "soft_variant": "substitute", // 软改写类别（本轮新增）
    "training_value": 0.95
  },
  "verification": {
```

```

    "structural": {"ok": true},
    "metric_check": {"checker": "sympy_verify.is_vacuum_einstein",
                      "status": "ok", "vacuum": true},
    "judge": {"correct": true, "self_contained": true,
              "training_value": 0.9, "issue": ""},
    "red_team": {"survives": true, "flaw": ""},
    "stage_eval": {"ok": true, "score": 0.75}
  }
}

```

字段要点:

- **lineage**: 从语料一路追溯的 ID 链, 每经过一个 stage 追加一个 ID。合并多组数据时这是唯一去重依据, 硬性必填。
- **source_type**: 标记输入源。教材 / 习题集扒下来的原题, Stage 0 的输入是章节 ID, lineage 里第一个 ID 是章节 ID, 第二个是原题 ID。
- **cognitive_form / physics_env / soft_variant**: 本轮三个多样性轴。validate.py 按这三轴统计覆盖度。
- **verification**: 哪些验证环节跑了、各自的判定。至少要有一项 judge (独立 LLM 调用), 加上至少一项客观校验 (structural / metric_check / unit_check / limit_check 等)。允许某项写“未跑”, 但不要默认填 ok=true。

B. 原型机实验数据 (参考 baseline)

B.1 B.1 端到端日志摘录

```

=== Prototype: paper -> training problems ===
paper:  arXiv-1002.4928v2/articlef.tex (423239 chars TeX)

[seed(data_group)]      attempt 1/2: outlet=2 ok=True score=0.93
                        judge passed 2/2, mean TV=0.93
Stage 0 produced 2 seed problems

scale pipeline = ['scale:cognitive_fanout', 'scale:metric_substitute']

--- seed 1/2 ---
  fanning out 6 parallel form-calls (max_workers=6)
  fanout produced 6/6 forms
[scale:cognitive_fanout] attempt 1/2: outlet=4 ok=True score=0.65
                        judge passed 6/6; red-team: 4/6 survived
  metric stage: 5 parallel calls (2 extend + 3 substitute)
  metric stage produced 4/5 variants
[scale:metric_substitute] attempt 1/2: outlet=3 ok=True score=0.75
                        judge passed 4/4; red-team: 3/4 survived

```



```

--- seed 2/2 ---
... (analogous: cognitive 4 + metric 4 入库)

scale pipeline produced 15 problems
FINAL training_dataset.jsonl: 15 problems

```

B.2 B.2 漏斗

stage	count
paper	1
seed problems (Stage 0)	2
scale pre-dedup	15
final training problems	15
amplification (paper $\rightarrow$ final)	15 $\times$

B.3 B.3 这次实跑产出的 15 道题全貌

2 道种子 (Stage 0 从论文里抽出, 覆盖论文的两条主线):

- 种子-1: $f(R)$ gravity stability conditions (ghost / tachyon free 条件)
- 种子-2: Starobinsky inflation in $f(R)$ gravity ($f(R) = R + R^2/6M^2$, 慢滚参数)

Cognitive fanout 阶段产出的 7 道 (同一种子在不同认知形式上的衍生):

form	topic	简述
derivation	$f(R)$ stability	推导 $f(R)$ gravity 与 scalar-tensor 理论的经典等价、写出 Einstein frame 作用量
numerical	Starobinsky inflation	给定 $N=55$ e-folds 数值计算 inflaton mass (得到 3.1×10^{13} GeV)
conceptual	Starobinsky inflation	解释为什么 plateau 形势能让 slow-roll 自然成立
code	Starobinsky inflation	写 Python 脚本数值求 n_s, r 并对照 large- N 解析近似
code	$f(R)$ stability	写脚本 sympy 自动算 f_R, f_{RR} 、解背景方程、线性化扰动
multiple_choice	$f(R)$ stability	4 选项, 3 个 distractor 是常见 sign/dimension 错误
open	$f(R)$ stability	设计题: 推导 scalaron mass 并讨论从辐射 $\rightarrow$ 物质 $\rightarrow$ 暗能量的过渡 (NO_ANSWER)

Metric substitute 阶段产出的 6 道 (同一类问题搬到不同时空背景上):

variant	metric / env	简述
substitute	FLRW_flat	把 $f(R)$ 修正 Friedmann 方程组写出来, 求 de Sitter 条件并解 scalaron 质量
substitute	Schwarzschild	计算 photon effective potential $V_l(r)$, 找 $r_0 = 3M$ 极值
substitute	deSitterStatic	de Sitter 视界 κ & Hawking 温度, 给定 $H_0 = 70 \text{ km/s/Mpc}$ 数值结果
substitute	FLRW_flat	Einstein-frame plateau 势能, 慢滚参数 ϵ, η
extend	同种子	计算 post-Newtonian γ , 讨论 $f(R)$ 模型在实验室引力实验里的约束
extend	同种子	求 third slow-roll 参数 ξ^2 , 推到 spectral running $\alpha_s \approx -6.6 \times 10^{-4}$

多样性轴的真实分布 (这一篇论文产出 15 道题的覆盖度):

- **cognitive 题型**: 9 种不同取值 (derivation / numerical / conceptual / code $\times 2$ / multiple_choice / open / substitute / extend);
- **物理环境**: 4 种 (原 paper 背景 + Schwarzschild + deSitterStatic + FLRW_flat);
- **topic 子主题**: 2 种 ($f(R)$ stability / Starobinsky inflation);
- **答案类型**: 14 道有解 + 1 道 NO_ANSWER (open 形式)。

按本轮指标”三轴各 ≥ 5 取值”看, 单篇论文还差一点 (环境 4 / topic 2 / open 1)。把多个论文的产出合并, 物理环境与 topic 自然就拉开了; 而 cognitive 题型上单篇就 9 种, 余量充足。

B.4 B.4 三道代表性样题 (节选)

样题 1 —Cognitive fanout / multiple_choice ($f(R)$ stability)

Statement (节选): In $f(R)$ gravity, the scalaron field has an effective mass squared $m_{\text{eff}}^2 = (f_R - R f_{RR})/(3f_{RR})$. Consider the model $f(R) = R + \alpha R^2 - \beta R^3$ at the de Sitter point $R = R_0$. Which of the following is the correct dimensionally consistent expression for m_{eff}^2 ?

Options (节选): A. $m^2 = (1 + 2\alpha R_0 - 3\beta R_0^2)/[3(2\alpha - 6\beta R_0)]$ B. (sign error) C. (dropped factor of 3) D. (units mismatch)

Answer: A. *Why distractors fail*: B 把 f_{RR} 的符号搞反; C 漏了分母 3; D 把 f_R 当作 $\partial f/\partial R$ 之外的量 (混淆 proper / coordinate)。判官评: correct=true, training_value=0.6; 红队: survives。

样题 2 —Metric substitute / Schwarzschild (photon $V_l(r)$)

Statement (节选): Consider the Schwarzschild metric $ds^2 = -(1-2M/r)dt^2 + (1-2M/r)^{-1}dr^2 + r^2 d\Omega^2$. For a massless scalar perturbation with angular momentum quantum number l , derive the effective potential $V_l(r)$ in the tortoise coordinate. Show that the potential has a maximum at $r_0 = 3M$, compute $V_0 = V_l(r_0)$ and its second derivative $V_l''(r_0)$.

Answer (节选): $V_l(r) = (1 - 2M/r)[l(l+1)/r^2 + 2M/r^3]$, $r_0 = 3M$, $V_0 = l(l+1)/(27M^2) + 2/(27M^2) \cdot 1$, $V_l''(r_0) = -[l(l+1)/(243M^4) + \dots]$ 。metric_check: status=ok (Schwarzschild 真空解、独立 sympy 验证); 判官: TV=0.9, correct=true; 红队: survives。

样题 3 —Cognitive fanout / code (Starobinsky n_s, r)

Statement (节选): Write a Python script that: (i) numerically computes the slow-roll parameters $\varepsilon(\phi), \eta(\phi)$ for the Einstein-frame potential $V(\phi) = V_0(1 - e^{-\sqrt{2/3}\phi/M_{\text{Pl}}})^2$; (ii) solves $\varepsilon = 1$ for ϕ_{end} ; (iii) given $N = 55$ e-folds, finds ϕ_* and reports n_s, r ; (iv) compares against the large- N analytical approximations $n_s \simeq 1 - 2/N, r \simeq 12/N^2$.

Answer: 数值结果 $n_s = 0.9650, r = 0.00350$; 近似 $n_s \simeq 0.9636$ (误差 0.14%), $r \simeq 0.00397$ (误差 13.4%)。tools_used: [llm_reasoning, code_exec]; 判官: TV=0.75; 红队: survives。

B.5 B.5 这版原型机产出的题目特征总结

- **物理推理深度**: 所有题目都需要至少 1 次非平凡的张量计算 / 度规几何推导 / 慢滚展开 / 微扰展开, 单纯 plug-in 数值的题目占比 1/15;
- **形式多样**: 一篇论文内就出现了 9 种不同认知形式, 包括”写代码 + 对比解析”和”找出 distractor 中的具体物理误解”这两类比较硬的;
- **答案类型**: 14 道带具体答案 (含数值 / 解析表达式 / 推导链), 1 道 NO_ANSWER 标记的开放设计题;
- **验证记录**: 每道题都附判官 verdict + 红队 verdict + (metric 题) 独立 sympy 验证; 13/15 通过红队, 2 道带瑕疵但保留并在 judge.issue 标记;
- **lineage 完整**: 每道题可逆向追溯到 arXiv-1002.4928v2 $\rightarrow$ 种子 ID $\rightarrow$ 自身 ID。

按这种产出水平推算 50 篇论文的最终数据集: cognitive 题型至少 9 种, 物理环境 (≥ 5 篇 GR 论文 + ≥ 5 篇 SR 论文) ≥ 8 种背景, 主题覆盖面非常宽。本轮指标”三轴各 ≥ 5 ”在合并多篇产出后是宽松目标。

C. 脚本骨架（直接抄）**C.1 C.1 validate.py (约 60 行)**

```
"""validate.py — 数据集合规与覆盖度自检。
用法: python validate.py dataset.jsonl
"""

import json, sys, hashlib, random
from collections import Counter

REQUIRED_TOP    = ["id", "statement", "answer", "meta", "verification"]
REQUIRED_META   = ["source_id", "source_type", "stage", "lineage"]

def main(path):
    items, errs = [], []
    for ln, line in enumerate(open(path, encoding="utf-8"), 1):
        try:    p = json.loads(line)
        except Exception as e:
            errs.append(f"line{ln}: not JSON: {e}"); continue
```

```

    for k in REQUIRED_TOP:
        if k not in p: errs.append(f"line{ln}: missing top-level '{k}'")
    for k in REQUIRED_META:
        if k not in p.get("meta", {}):
            errs.append(f"line{ln}: missing meta. '{k}'")
    if not p.get("answer"):
        errs.append(f"line{ln}: empty answer (use NO_ANSWER if open)")
    if not p.get("verification", {}).get("judge"):
        errs.append(f"line{ln}: no judge verification record")
    items.append(p)

print(f"== validate {path} ==")
print(f"total: {len(items)}, errors: {len(errs)}")
if errs[:5]: print("first errors:\n  " + "\n  ".join(errs[:5]))

by_src = Counter(p["meta"].get("source_id", "?") for p in items)
by_type = Counter(p["meta"].get("source_type", "?") for p in items)
by_form = Counter(p["meta"].get("cognitive_form", "?") for p in items)
by_env = Counter(p["meta"].get("physics_env", "?") for p in items)
by_soft = Counter(p["meta"].get("soft_variant", "?") for p in items)
print(f"\nsources covered: {len(by_src)}; by type: {dict(by_type)}")
print(f"cognitive_form distinct: {len(by_form)}; values: {dict(by_form.
    most_common(8))}")
print(f"physics_env distinct: {len(by_env)}; values: {dict(by_env.
    most_common(8))}")
print(f"soft_variant distinct: {len(by_soft)}; values: {dict(by_soft.
    most_common(8))}")

print("\n== random 10 sample ids ==")
for p in random.sample(items, min(10, len(items))):
    print(f"  {p['id']} src={p['meta']['source_id']} "
          f"form={p['meta'].get('cognitive_form', '?')} "
          f"TV={p['meta'].get('training_value', '?')}")

if __name__ == "__main__": main(sys.argv[1])

```

C.2 C.2 sample.py (约 30 行)

```

"""sample.py — 按维度抽样出 markdown 报告。
用法: python sample.py dataset.jsonl --n 20 --by source_id [--out sample.md]
"""

import json, argparse, random
from collections import defaultdict

def main():

```

```

ap = argparse.ArgumentParser()
ap.add_argument("path"); ap.add_argument("--n", type=int, default=20)
ap.add_argument("--by", default="source_id",
                 choices=["source_id", "source_type", "cognitive_form",
                          "physics_env", "soft_variant", "random"])
ap.add_argument("--out", default="sample.md")
args = ap.parse_args()
items = [json.loads(l) for l in open(args.path)]
if args.by == "random":
    picks = random.sample(items, min(args.n, len(items)))
else:
    groups = defaultdict(list)
    for p in items: groups[p["meta"].get(args.by, "?")].append(p)
    picks = [random.choice(v) for v in groups.values()][:args.n]
with open(args.out, "w", encoding="utf-8") as f:
    for p in picks:
        f.write(f"### {p['id']}\n- src: {p['meta']['source_id']}"
               f" ({p['meta'].get('source_type', '?')})\n")
        f.write(f"- form: {p['meta'].get('cognitive_form', '?')}, "
               f"env: {p['meta'].get('physics_env', '?')}\n\n")
        f.write(f"**Q.** {p['statement'][:600]}...\n\n")
        f.write(f"**A.** {(p.get('answer') or '')[:300]}...\n\n---\n\n")
    print(f"wrote {len(picks)} samples to {args.out}")

if __name__ == "__main__": main()

```

C.3 C.3 run_report.md 模板

```

# Run Report — <组名>

## 工作模式
- mode: A / B / C (paper / textbook / mixed)
- sources count: 50 papers + 0 chapters / etc.

## Funnel
| stage | total | kept | skipped | failed |
|---|---|---|---|---|
| sources ingested | 50 | 47 | 2 | 1 |
| seeds produced | 92 | 88 | - | 4 |
| cognitive variants | ... | ... | - | ... |
| metric variants | ... | ... | - | ... |
| **final dataset** | **1024** | - | - | - |

## Diversity coverage
- cognitive_form: 8 distinct (derivation, numerical, ..., reduce)

```

```
- physics_env:      6 distinct (Schwarzschild, FLRW, deSitter, ..., SR_boost)
- soft_variant:     5 distinct (substitute, extend, contrast, design, reduce)

## Failed sources (skip / partial)
| source_id | type | status | reason |
|---|---|---|---|
| arXiv-XXXX | paper | skip | tex 解析失败, document body 抽不出来 |
| arXiv-YYYY | paper | partial | seed stage 5/6 通过, 仅产出 12 道 |
| Carroll-Ch5 | textbook | partial | OCR 漏识别 3 道方程, 已手动修复 8 道 |

## What worked / didn't
- 工作得很好的事: ...
- 没工作好但尝试过的事: ...
- 完全没尝试的事 (并解释原因): ...

## Token / wall-clock estimate
- 总 LLM 调用: ~3500 次
- 估计 output token: ~6.2M
- 端到端 wall-clock: ~38 小时 (含 cache hit)
```