

hw_pipeline 技术报告

广义相对论题目泛化流水线

2026 年 5 月

目录

1 概述	3
2 架构	3
3 两阶段泛化	3
3.1 Phase 1: 同度规延伸	3
3.2 Phase 2: 度规替换	4
3.3 度规库	4
4 Fact Sheet	4
5 验证-修正循环	5
5.1 验证	5
5.2 修正循环	5
6 LLM 配置	5
7 JSON Schema	6
8 Prompts 关键规则	6
9 Cleaner	7
10 正确性保证	7
11 项目结构	7
12 已解决问题	8

13 待验证问题	8
14 后续方向	8
附注：确定性标注	9

1 概述

hw_pipeline 从一道种子 GR 题目出发，自动生成多道可独立求解的新题目。核心思路是两阶段泛化：Phase 1 保持原度规、LLM 自选方向延伸种子题；Phase 2 将题目适配到新度规。正确性由 SymPy/EinsteinPy 的 Fact Sheet 保证。

[已确认] 流水线架构已实现并可运行。[待验证] 题目质量尚未经人工评审。

2 架构

五个子命令：

```
python main.py run input.md --num 3 --subs 2 # 一步完成
python main.py abstract input.md # 自然语言 → JSON
python main.py generate seed.json # 泛化生成
python main.py validate variants/*.json # 验证+修正
python main.py clean variants/*.json # 清理排版
```

数据流：

阶段	输入	输出
abstract	PDF/Image/MD	种子 JSON
缓存	种子 JSON	种子 JSON + cached_fact_sheet
Phase 1	种子 JSON + Fact Sheet	N 道基础题 JSON
Phase 2	基础题 + 新度规 Fact Sheet	$N \times M$ 道替换题 JSON
validate	题目 JSON	validated JSON

3 两阶段泛化

3.1 Phase 1：同度规延伸

[已确认] 保持种子题的度规不变，LLM 自选泛化方向编题：

- LLM (COMPOSE prompt) 基于 Fact Sheet + 种子题自行选择有意义的延伸方向
- 强制 physical_data 使用种子题的度规（覆写 LLM 输出）
- 输出必须是独立完整题目（含物理背景、度规定义、所有假设）
- 每道题只能有一问，难度与种子题相当

3.2 Phase 2: 度规替换

[已确认] 将基础题适配到新度规，保持题目类型和结构不变：

- LLM (PICK_METRIC) 一次性从度规库挑选 M 个替换度规
- 所有基础题共享同一组替换度规（减少 API 调用）
- LLM (SUBSTITUTE) 适配原题到新度规
- 替换后 Fact Sheet 由 SymPy 重新计算

[待验证] 度规替换的物理合理性依赖 LLM 适配能力。不同物理场景（黑洞 vs 宇宙学）的转换可能不自然。

3.3 度规库

8 个核心度规（均非 heavy，Fact Sheet < 30s）：

度规	描述
Schwarzschild	静态球对称黑洞，真空解
Minkowski / MinkowskiCartesian / MinkowskiPolar	平直时空三种坐标
DeSitter	正宇宙学常数
AntiDeSitter / AntiDeSitterStatic	负宇宙学常数
FLRW	标度因子 $a(t)$

Heavy 度规（Kerr、Ernst、KerrNewman、AlcubierreWarp、BesselGravitationalWave、ReissnerNordstrom）排除在替换候选外。

[待验证] FLRW 含 $a(t)$ 函数，Fact Sheet 分量可能含其导数，LLM 编题时能否正确使用尚不确定。

4 Fact Sheet

EinsteinPy 符号计算生成：Christoffel Γ_{ij}^k 、Riemann R_{ijk}^l 、Ricci R_{ij}/R 、Kretschmann $K = R_{ijkl}R^{ijkl}$ 、Einstein $G_{\mu\nu}$ 。所有分量经 sympy.simplify 简化后存为 LaTeX。

[已确认] 符号计算确定性，给定度规和变量，结果唯一且绝对正确。

[已确认] Fact Sheet 可缓存到种子 JSON 的 cached_fact_sheet 字段。run 子命令自动缓存。

[待验证] LaTeX→SymPy 转换（用于无 metric_sympy 的旧 JSON）对非标准格式的鲁棒性有限。流水线尽量使用 metric_sympy 或度规库直接提供的 SymPy 格式。

5 验证-修正循环

5.1 验证

VALIDATE prompt 聚焦可解性和自洽性：

1. 可解性：目标能否推导？缺少必要条件？
2. 自洽性：度规与题干一致？中间量与 Fact Sheet 一致？
3. 完整性：做题者能否独立完成？

[已确认] answer 为”无答案”→ verified=false（不可解）。

5.2 修正循环

validate_and_fix_loop (max_attempts=2)：

1. 计算 Fact Sheet（只算一次）
2. validate → 若通过则结束
3. 若失败且有 issues → fix → 重新验证
4. 重复直到通过或达到上限

修正规则：度规和 metadata.id/source 不可修改；只修正 origin(answer/solution/hint)；严重错误 → answer=”无答案”。

[已确认] 三个退出路径均添加 tools_used 标记：EinsteinPy + validate:{model}。

[待验证] 修正循环依赖 LLM 修正能力，可能引入新错误。LLM 验证的判断标准不明确，不同调用可能给出不同结论。

6 LLM 配置

各阶段模型通过.env 环境变量配置，未设置时回退到 DEFAULT_MODEL：

阶段	当前模型
abstract / pick_metric	qwen3.6-flash
compose / substitute / validate / fix	glm-5.1

API：DashScope Anthropic 兼容接口，指数退避重试（最多 3 次），超时 600s，max_tokens 32768。

[已确认] JSON 解析鲁棒性：剔除 markdown 代码块 + 修正无效 LaTeX 转义 + 字段过滤。

[待验证] API 并发限制未知；不同模型的 JSON 输出格式稳定性待验证。

7 JSON Schema

```
{
  "metadata": {
    "id": "test-gen-0",
    "type": "calculate",          // prove | calculate | concept
    "tags": { metric, target_object, coordinate, scenario, method },
    "tools_used": ["EinsteinPy", "validate:glm-5.1"],
    "validated": true,
    "source": "generated"
  },
  "physical_data": {
    "dimension": 4,
    "variables": ["$t$", "$r$", "$\\theta$", "$\\phi$"],
    "target": ["$\\Gamma_{01}^{1}$"],
    "metric": [[...], ...],      // LaTeX NxN
    "metric_sympy": [[...], ...] // SymPy NxN
  },
  "origin": {
    "question": "...",          // 独立完整题干
    "answer": "...",            // 结论或"无答案"
    "solution": "...",          // 推导思路或 null
    "hint": ["..."]             // 提示列表或 null
  }
}
```

8 Prompts 关键规则

阶段	关键规则
ABSTRACT	origin 保留原文照抄；每题一问
COMPOSE	LLM 自选泛化方向；度规不可修改；独立完整题；难度与种子题相当
SUBSTITUTE	保持题目类型和结构；用新度规数据替换
PICK_METRIC	不选当前度规和 heavy 度规
VALIDATE	聚焦可解性 + 自洽性；不可解 $\rightarrow$ false
FIX	度规和 metadata 不可修改；严重错误 $\rightarrow$ “无答案”

所有 prompt 限制题目范围：只涉及 GR 张量计算与基本应用，严禁引力波、量子引力、宇宙学精细模型等。

solution 引用几何量直接写公式（不标注来源），hint 只写符号约定和特殊简化。

[待验证] Prompt 约束无法完全防止 LLM 偏离要求，代码层覆写是最后一道防线。

9 Cleaner

两步清理：1) `_remove_newlines` 一递归移除所有字符串中的 `\n`；2) `_clean_string` 一只在 `$$...$$` 和 `$...$` 数学段内移除空格。`metric_sympy` 不参与第二步。

[待验证] 嵌套数学段的正则匹配可能有潜在风险。

10 正确性保证

三层机制：

1. **SymPy Fact Sheet**：确定性符号计算，绝对正确
2. **LLM 验证-修正**：Fact Sheet 为基准，LLM 检查一致性
3. **代码覆写**：`physical_data` 从种子/度规库获取，不依赖 LLM

[待验证] 三层机制保证度规正确性和结构完整性，但不保证 `answer/solution` 的物理正确性。LLM 可能引用正确数据得出错误结论。

11 项目结构

```
hw_pipeline/
  main.py           # CLI 入口
  .env / .env.example
  schema/schema.py  # Problem dataclass
  core/
    config.py        # 环境变量配置
    api_client.py    # DashScope API (Anthropic 协议)
    formatter.py     # abstract: 自然语言 → JSON
    pipeline.py      # generate: 两阶段泛化
    system_prompts.py # 6 个 LLM prompts
    sympy_engine.py  # EinsteinPy Fact Sheet
    metric_library.py # 度规库
    cleaner.py       # JSON 清理
    validator.py     # 验证-修正循环
    file_converter.py # PDF/Word → 图片
```

12 已解决问题

1. LLM 返回额外字段 → dataclass 字段过滤
2. LaTeX 转义错误 → 双重转义规则 + JSON 解析 fallback
3. Fact Sheet 重复计算 → 缓存 cached_fact_sheet
4. 3 维度规 Fact Sheet → 限制度规库为 4 维
5. ReissnerNordstrom eps_0 → 标记 heavy 并排除
6. 速度瓶颈 → pick_metric 一次性调用；并发执行；Phase 1 不生成新度规

13 待验证问题

1. [待验证] LLM 验证可靠性：能否准确判断可解性？需要人工抽样验证准确率。
2. [待验证] 修正循环有效性：修正后是否比修正前更好？还是引入新错误？
3. [待验证] 度规替换的物理合理性：不同场景转换是否自然？
4. [待验证] 难度一致性：LLM 能否准确把握难度？
5. [待验证] FLRW 的 $a(t)$ 导数：LLM 能否正确使用含导数的 Fact Sheet？
6. [待验证] API 并发限制：DashScope rate limit 未知。
7. [待验证] LLM 自选方向的质量：去掉方向池后，LLM 选择的泛化方向是否有意义且多样化？是否会趋向某些固定方向？

14 后续方向

1. [已确认] 人工评审基准：统计 validate 准确率和题目质量分布。
2. [待验证] heavy 度规支持：优化 Kretschmann 计算，使 Kerr 可用于替换。
3. [待验证] structured output：用 JSON schema 约束 LLM 输出格式。
4. [待验证] 多模型交叉验证：减少单模型偏差。
5. [待验证] 题目质量评分：教学价值、难度一致性、题干清晰度。

附注：确定性标注

[已确认] 一代码验证或逻辑推理确认，可信度高。[待验证] 一推测或有限测试，需进一步验证，是后续审阅的重点。